

Гаврилов Л.Я. ИУ5-23М

▼ Обработка признаков (часть 1).

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

▼ Загрузка и первичный анализ данных

Используем датасет [PC Games 2020](#) игр Steam с добавлением данных RAWG API

```
data = pd.read_csv('games.csv', sep=",")
```

```
data.shape
```

```
(30250, 27)
```

```
data.dtypes
```

```
Unnamed: 0      int64
id              int64
Name           object
RawgID         float64
SteamURL       object
Metacritic     float64
Genres        object
Indie         float64
Presence      float64
Platform      object
Graphics      object
Storage       object
Memory        object
RatingsBreakdown object
ReleaseDate   object
Soundtrack    float64
Franchise     object
OriginalCost  object
DiscountedCost object
Players       object
Controller    float64
Languages     object
ESRB         object
Achievements float64
Publisher     float64
Description   object
Tags          object
dtype: object
```

```
data.isnull().sum()
```

```
Unnamed: 0      0
id              0
Name           94
RawgID         94
SteamURL       55
Metacritic     26894
Genres        2968
Indie         205
Presence      94
Platform      127
Graphics     4320
Storage      2759
Memory       1934
RatingsBreakdown 15206
ReleaseDate   3226
Soundtrack    205
Franchise     25163
OriginalCost   746
DiscountedCost 29523
Players       17916
Controller     274
Languages     223
```

```
ESRB                25503
Achievements        94
Publisher            30250
Description          219
Tags                205
dtype: int64

data.head()
```

	Unnamed: 0	id	Name	RawgID	SteamURL	Metacritic	Genres	Indie	Presence	Platform	...
0	0	1	Counter-Strike: Global Offensive	4291.0	https://store.steampowered.com/app/730/?snr=1_...	83.0	Action, Free to Play	0.0	1009588.0	PC, Xbox 360, PlayStation 3	...
1	1	2	Destiny 2	32.0	https://store.steampowered.com/app/1085660/?sn...	82.0	Action, Adventure, Free to Play	0.0	1007425.0	PlayStation 5, Web, Xbox Series X, PC, Xbox On...	...
2	2	3	Dota 2	10213.0	https://store.steampowered.com/app/570/?snr=1_...	90.0	NaN	0.0	1009306.0	Linux, macOS, PC	...
3	3	4	The Elder Scrolls Online	41458.0	https://store.steampowered.com/app/306130/?snr...	71.0	Massively Multiplayer, RPG	0.0	1000781.0	PC	...
4	4	5	Sea of Thieves	50781.0	https://store.steampowered.com/app/1172620/?sn...	68.0	Action, Adventure	0.0	777456.0	PC, Xbox One	...

5 rows × 27 columns

```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))

Всего строк: 30250
```

Устранение пропусков в данных

```
hcols_with_na = [c for c in data.columns if data[c].isnull().sum() > 0]
# Количество пропусков
[(c, data[c].isnull().sum()) for c in hcols_with_na]

[('Name', 94),
 ('RawgID', 94),
 ('SteamURL', 55),
 ('Metacritic', 26894),
 ('Genres', 2968),
 ('Indie', 205),
 ('Presence', 94),
 ('Platform', 127),
 ('Graphics', 4320),
 ('Storage', 2759),
 ('Memory', 1934),
 ('RatingsBreakdown', 15206),
 ('ReleaseDate', 3226),
 ('Soundtrack', 205),
 ('Franchise', 25163),
 ('OriginalCost', 746),
 ('DiscountedCost', 29523),
 ('Players', 17916),
 ('Controller', 274),
 ('Languages', 223),
 ('ESRB', 25503),
 ('Achievements', 94),
 ('Publisher', 30250),
```

https://colab.research.google.com/drive/1dAyOKRnCCR1-Mmu3JVlCdIneQ6_I9ozb?hl=ru#scrollTo=Lm0E7WCStg_p&printMode=true

2/14

```

('Description', 219),
('Tags', 205]]

# Доля (процент) пропусков
[(c, data[c].isnull().mean()) for c in hcols_with_na]

[(('Name', 0.0031074380165289255),
  ('RawgID', 0.0031074380165289255),
  ('SteamURL', 0.0018181818181818182),
  ('Metacritic', 0.8890578512396694),
  ('Genres', 0.09811570247933885),
  ('Indie', 0.006776859504132231),
  ('Presence', 0.0031074380165289255),
  ('Platform', 0.004198347107438017),
  ('Graphics', 0.1428099173553719),
  ('Storage', 0.09120661157024794),
  ('Memory', 0.06393388429752066),
  ('RatingsBreakdown', 0.5026776859504132),
  ('ReleaseDate', 0.10664462809917355),
  ('Soundtrack', 0.006776859504132231),
  ('Franchise', 0.8318347107438017),
  ('OriginalCost', 0.02466115702479339),
  ('DiscountedCost', 0.9759669421487603),
  ('Players', 0.5922644628099174),
  ('Controller', 0.009057851239669422),
  ('Languages', 0.007371900826446281),
  ('ESRB', 0.8430743801652892),
  ('Achievements', 0.0031074380165289255),
  ('Publisher', 1.0),
  ('Description', 0.007239669421487603),
  ('Tags', 0.006776859504132231)]

# Удаление колонки Publisher и Unnamed: 0 из-за неиспользования в данной работе связей с другими датасетами
data = data.drop('Publisher', 1)
data = data.drop('Unnamed: 0', 1)
data.shape

<ipython-input-46-db29e5716c4b>:2: FutureWarning: In a future version of pandas all arguments of DataFrame.drop except for the argu
data = data.drop('Publisher', 1)
<ipython-input-46-db29e5716c4b>:3: FutureWarning: In a future version of pandas all arguments of DataFrame.drop except for the argu
data = data.drop('Unnamed: 0', 1)
(30250, 25)

# Колонки для которых удаляются пропуски
data = data.dropna(axis=0, subset=['Name', 'SteamURL'])
data.shape

(30101, 25)

hcols_with_na = [c for c in data.columns if data[c].isnull().sum() > 0]
# Количество пропусков
[(c, data[c].isnull().sum()) for c in hcols_with_na]

[(('Metacritic', 26746),
  ('Genres', 2907),
  ('Indie', 176),
  ('Platform', 33),
  ('Graphics', 4250),
  ('Storage', 2697),
  ('Memory', 1872),
  ('RatingsBreakdown', 15112),
  ('ReleaseDate', 3132),
  ('Soundtrack', 176),
  ('Franchise', 25024),
  ('OriginalCost', 688),
  ('DiscountedCost', 29374),
  ('Players', 17813),
  ('Controller', 219),
  ('Languages', 168),
  ('ESRB', 25355),
  ('Description', 125),
  ('Tags', 176)]

```

▼ Заполнение значений для одного признака

▼ "Внедрение значений" - импьютация (imputation)

▼ Обработка пропусков в числовых данных

```
# Выберем числовые колонки с пропущенными значениями
# Цикл по колонкам датасета
num_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='float64' or dt=='int64'):
        num_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%'.format(col, dt, temp_null_count, temp_perc))
```

Колонка Metacritic. Тип данных float64. Количество пустых значений 26746, 88.42%.
 Колонка Indie. Тип данных float64. Количество пустых значений 176, 0.58%.
 Колонка Soundtrack. Тип данных float64. Количество пустых значений 176, 0.58%.
 Колонка Controller. Тип данных float64. Количество пустых значений 219, 0.72%.

```
# Фильтр по колонкам с пропущенными значениями
data_num = data[num_cols]
data_num
```



	Metacritic	Indie	Soundtrack	Controller
0	83.0	0.0	0.0	1.0
1	82.0	0.0	0.0	1.0
2	90.0	0.0	0.0	1.0
3	71.0	0.0	0.0	1.0
4	68.0	0.0	0.0	1.0
...
30245	NaN	1.0	0.0	1.0
30246	NaN	1.0	0.0	0.0
30247	NaN	0.0	0.0	0.0
30248	NaN	1.0	0.0	1.0
30249	NaN	0.0	0.0	1.0

30101 rows × 4 columns

```
# Определим уникальные значения для полей
(data['Soundtrack'].unique(),
 data['Controller'].unique(),
 data['Indie'].unique())

(array([ 0.,  1., nan]), array([ 1.,  0., nan]), array([ 0.,  1., nan]))
```

```
# Гистограмма по признакам
for col in data_num:
    plt.hist(data[col], 50)
    plt.xlabel(col)
    plt.show()
```



```
data_num_Metacritic = data_num[['Metacritic']]
data_num_Metacritic.head()
```

	Metacritic
0	83.0
1	82.0
2	90.0
3	71.0
4	68.0

12000 | |

```
def research_impute_numeric_column(dataset, num_column, const_value=None):
    strategy_params = ['mean', 'median', 'most_frequent', 'constant']
    strategy_params_names = ['Среднее', 'Медиана', 'Мода']
    strategy_params_names.append('Константа = ' + str(const_value))


    original_temp_data = dataset[[num_column]].values
    size = original_temp_data.shape[0]
    original_data = original_temp_data.reshape((size,))

    new_df = pd.DataFrame({'Исходные данные':original_data})

    for i in range(len(strategy_params)):
        strategy = strategy_params[i]
        col_name = strategy_params_names[i]
        if (strategy!='constant') or (strategy == 'constant' and const_value!=None):
            if strategy == 'constant':
                temp_data, _, _ = impute_column(dataset, num_column, strategy, fill_value_param=const_value)
            else:
                temp_data, _, _ = impute_column(dataset, num_column, strategy)
            new_df[col_name] = temp_data

    sns.kdeplot(data=new_df)

research_impute_numeric_column(data, 'Metacritic', 50)
```



```
from sklearn.impute import SimpleImputer
from sklearn.impute import MissingIndicator
```

Попробуем заполнить пропущенные значения в колонке Metacritics значениями, вычисленными по среднему арифметическому, медиане и моде.

```
strategies=['mean', 'median', 'most_frequent']
```

```
def test_num_impute(strategy_param):
    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(data_num_Metacritic)
    return data_num_imp[mask_missing_values_only]
```

```
strategies[0], test_num_impute(strategies[0])
```

```
('mean', array([72.92280179, 72.92280179, 72.92280179, ..., 72.92280179,
72.92280179, 72.92280179]))
```

```
strategies[1], test_num_impute(strategies[1])
```

```
('median', array([74., 74., 74., ..., 74., 74., 74.]))
```

```
strategies[2], test_num_impute(strategies[2])
```

```
('most_frequent', array([80., 80., 80., ..., 80., 80., 80.]))
```

Более сложная функция, которая позволяет задавать колонку и вид импутации

```
def test_num_impute_col(dataset, column, strategy_param):
    temp_data = dataset[[column]]

    indicator = MissingIndicator()
    mask_missing_values_only = indicator.fit_transform(temp_data)

    imp_num = SimpleImputer(strategy=strategy_param)
    data_num_imp = imp_num.fit_transform(temp_data)

    filled_data = data_num_imp[mask_missing_values_only]

    return column, strategy_param, filled_data.size, filled_data[0], filled_data[filled_data.size-1]
```

```
data[['Metacritic']].describe()
```

	Metacritic
count	3355.000000
mean	72.922802
std	10.806216
min	20.000000
25%	67.000000
50%	74.000000
75%	80.000000
max	97.000000

```
test_num_impute_col(data, 'Metacritic', strategies[0])
```

```
('Metacritic', 'mean', 26746, 72.92280178837557, 72.92280178837557)
```

```
test_num_impute_col(data, 'Metacritic', strategies[1])
```

```
('Metacritic', 'median', 26746, 74.0, 74.0)
```

```
test_num_impute_col(data, 'Metacritic', strategies[2])
```

```
('Metacritic', 'most_frequent', 26746, 80.0, 80.0)
```

▼ Обработка пропусков в категориальных данных

```
# Выберем категориальные колонки с пропущенными значениями
# Цикл по колонкам датасета
cat_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>0 and (dt=='object'):
        cat_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {:.1f}'.format(col, dt, temp_null_count, temp_perc))
```

```
Колонка Genres. Тип данных object. Количество пустых значений 2907, 9.61%.
Колонка Platform. Тип данных object. Количество пустых значений 33, 0.11%.
Колонка Graphics. Тип данных object. Количество пустых значений 4250, 14.05%.
Колонка Storage. Тип данных object. Количество пустых значений 2697, 8.92%.
Колонка Memory. Тип данных object. Количество пустых значений 1872, 6.19%.
Колонка RatingsBreakdown. Тип данных object. Количество пустых значений 15112, 49.96%.
Колонка ReleaseDate. Тип данных object. Количество пустых значений 3132, 10.35%.
Колонка Franchise. Тип данных object. Количество пустых значений 25024, 82.72%.
Колонка OriginalCost. Тип данных object. Количество пустых значений 688, 2.27%.
Колонка DiscountedCost. Тип данных object. Количество пустых значений 29374, 97.1%.
Колонка Players. Тип данных object. Количество пустых значений 17813, 58.89%.
Колонка Languages. Тип данных object. Количество пустых значений 168, 0.56%.
Колонка ESRB. Тип данных object. Количество пустых значений 25355, 83.82%.
Колонка Description. Тип данных object. Количество пустых значений 125, 0.41%.
Колонка Tags. Тип данных object. Количество пустых значений 176, 0.58%.
```

- Колонки, содержащие менее 5% пропусков выбираем для построения модели.
- Колонки, содержащие менее 30% пропусков также выбираем для построения модели.
- Колонки RatingsBreakdown (49.96%) и Players (59.07%) не выбираем для построения модели, в случае отсутствия необходимости в этих колонках.
- Колонки Franchise (82.91%), DiscountedCost (97.29%) и ESRB (84.0%) не выбираем для построения модели в любом случае.

```
cat_temp_data = data[['Genres']]
cat_temp_data.head()
```

	Genres
0	Action, Free to Play
1	Action, Adventure, Free to Play
2	NaN
3	Massively Multiplayer, RPG
4	Action, Adventure

```
cat_temp_data['Genres'].unique()

array(['Action, Free to Play', 'Action, Adventure, Free to Play', nan,
..., 'Casual, Indie, Massively Multiplayer, RPG, Early Access',
'Action, Adventure, Casual, Racing, Simulation, Strategy',
'Action, Adventure, Casual, Sports, Strategy'], dtype=object)
```

```
cat_temp_data[cat_temp_data['Genres'].isnull()].shape

(2907, 1)
```

```
# Импутация наиболее частыми значениями
imp2 = SimpleImputer(missing_values=np.nan, strategy='most_frequent')
data_imp2 = imp2.fit_transform(cat_temp_data)
data_imp2
```

```
array([[ 'Action, Free to Play'],
[ 'Action, Adventure, Free to Play'],
[ 'Action, Indie'],
...,
[ 'Casual'],
[ 'Action, Adventure, Casual, Indie'],
[ 'Action, Indie']], dtype=object)
```

```
# Пустые значения отсутствуют
np.unique(data_imp2)
```

```

array(['Action', 'Action, Adventure', 'Action, Adventure, Casual', ...,
      'Strategy, Indie, Casual, Simulation', 'Strategy, RPG, Indie',
      'Strategy, Simulation'], dtype=object)

# Импутация константой
imp3 = SimpleImputer(missing_values=np.nan, strategy='constant', fill_value='NA')
data_imp3 = imp3.fit_transform(cat_temp_data)
data_imp3

array([[ 'Action, Free to Play'],
      ['Action, Adventure, Free to Play'],
      ['NA'],
      ...,
      ['Casual'],
      ['Action, Adventure, Casual, Indie'],
      ['NA']], dtype=object)

np.unique(data_imp3)

array(['Action', 'Action, Adventure', 'Action, Adventure, Casual', ...,
      'Strategy, Indie, Casual, Simulation', 'Strategy, RPG, Indie',
      'Strategy, Simulation'], dtype=object)

data_imp3[data_imp3=='NA'].size

2907

```

Таким образом, в колонку Genres вставлено 2962 "NA", вместо пропущенных значений.

▼ Преобразование категориальных признаков в числовые

```

cat_enc = pd.DataFrame({'c1':data_imp2.T[0]})
cat_enc

```

	c1
0	Action, Free to Play
1	Action, Adventure, Free to Play
2	Action, Indie
3	Massively Multiplayer, RPG
4	Action, Adventure
...	...
30096	Casual, Indie
30097	Indie
30098	Casual
30099	Action, Adventure, Casual, Indie
30100	Action, Indie

30101 rows × 1 columns

▼ Кодирование категорий целочисленными значениями - [label encoding](#)

```

from sklearn.preprocessing import LabelEncoder, OneHotEncoder

le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])

cat_enc['c1'].unique()

array(['Action, Free to Play', 'Action, Adventure, Free to Play',
      'Action, Indie', ...,
      'Casual, Indie, Massively Multiplayer, RPG, Early Access',
      'Action, Adventure, Casual, Racing, Simulation, Strategy',
      'Action, Adventure, Casual, Sports, Strategy'], dtype=object)

np.unique(cat_enc_le)

```



```
array([ 0, 1, 2, ..., 1003, 1004, 1005])
```

▼ Кодирование категорий наборами бинарных значений - [one-hot encoding](#)

```
ohe = OneHotEncoder()
cat_enc_ohe = ohe.fit_transform(cat_enc[['c1']])

cat_enc.shape

(30101, 1)

cat_enc_ohe.shape

(30101, 1006)

cat_enc_ohe

<30101x1006 sparse matrix of type '<class 'numpy.float64'>'
with 30101 stored elements in Compressed Sparse Row format>

cat_enc_ohe.todense()[0:10]

matrix([[0., 0., 0., ..., 0., 0., 0.],
        [0., 0., 0., ..., 0., 0., 0.],
        [0., 0., 0., ..., 0., 0., 0.],
        ...,
        [0., 0., 0., ..., 0., 0., 0.],
        [1., 0., 0., ..., 0., 0., 0.],
        [0., 0., 0., ..., 0., 0., 0.]])

cat_enc.head(10)
```

	c1
0	Action, Free to Play
1	Action, Adventure, Free to Play
2	Action, Indie
3	Massively Multiplayer, RPG
4	Action, Adventure
5	Adventure, Indie, Simulation, Strategy, Early ...
6	Action
7	Action, Indie, Racing, Sports
8	Action
9	Action, Adventure, Indie, Massively Multiplaye...

▼ [Pandas get_dummies](#) - быстрый вариант one-hot кодирования

```
pd.get_dummies(cat_enc).head()
```

- Count (frequency) encoding

10/14

	Achievements	Controller	Description	DiscountedCost	ESRB	Franchise	Graphics	Indie	Languages	Memory	...	Players	Pr
0	179.0	1.0	1	29374	776	25024	8	0.0	1	6462	...	65	10

```
ce_CountEncoder2 = ce_CountEncoder(normalize=True)
data_FREQ_ENC = ce_CountEncoder2.fit_transform(data[data.columns.difference(['Genres'])])
data_FREQ_ENC
```

	Achievements	Controller	Description	DiscountedCost	ESRB	Franchise	Graphics	Indie	Languages	Memory	...	Player:
0	179.0	1.0	0.000033	0.975848	0.025780	0.831335	0.000266	0.0	0.000033	0.214677	...	0.00215
1	61.0	1.0	0.000033	0.975848	0.047374	0.000033	0.000066	0.0	0.004219	0.015614	...	0.00461
2	0.0	1.0	0.000033	0.975848	0.842331	0.831335	0.000764	0.0	0.000033	0.207568	...	0.00215
3	0.0	1.0	0.000033	0.975848	0.842331	0.000066	0.000100	0.0	0.010697	0.011960	...	0.01784
4	308.0	1.0	0.000033	0.975848	0.047374	0.831335	0.000033	0.0	0.008538	0.207568	...	0.00215
...
30245	0.0	1.0	0.000033	0.975848	0.842331	0.831335	0.000664	1.0	0.567423	0.094249	...	0.59177
30246	0.0	0.0	0.000033	0.975848	0.842331	0.831335	0.000233	1.0	0.567423	0.015614	...	0.59177
30247	0.0	0.0	0.000033	0.975848	0.842331	0.000033	0.141191	0.0	0.567423	0.009667	...	0.59177
30248	0.0	1.0	0.000033	0.975848	0.842331	0.831335	0.141191	1.0	0.567423	0.008172	...	0.59177
30249	0.0	1.0	0.000033	0.975848	0.842331	0.831335	0.000897	0.0	0.567423	0.207568	...	0.59177

30101 rows × 24 columns

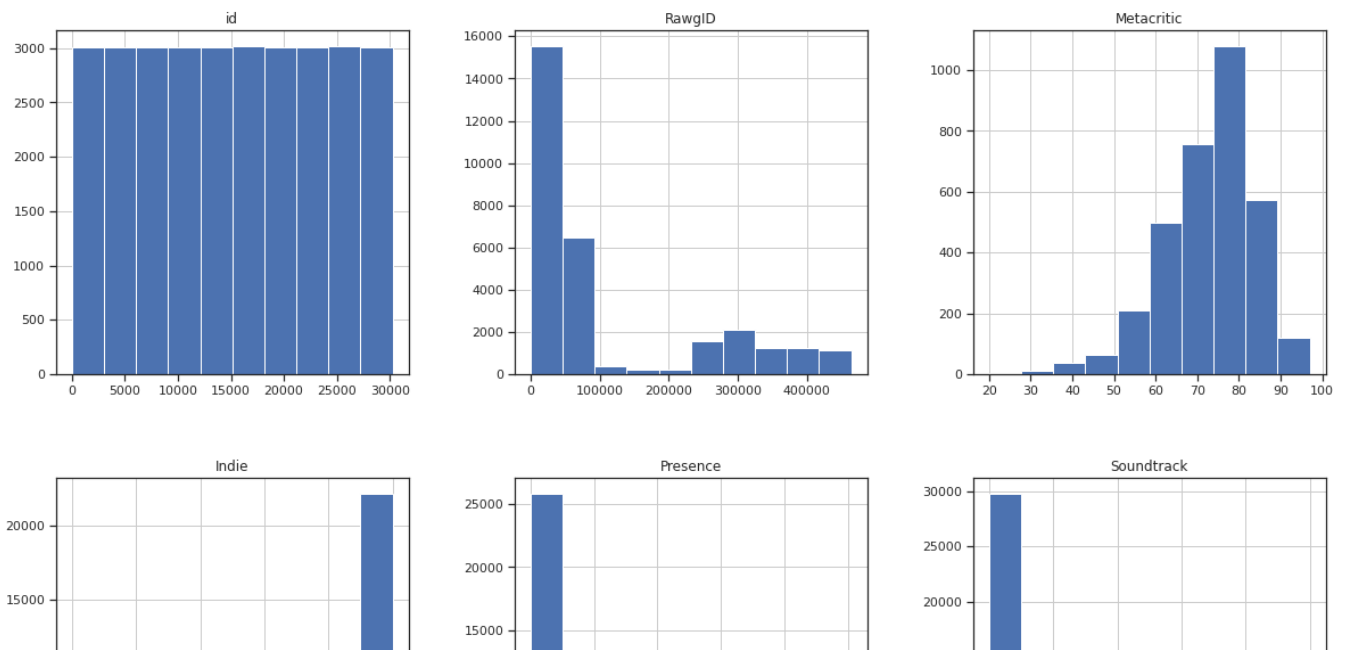


▼ Нормализация числовых признаков

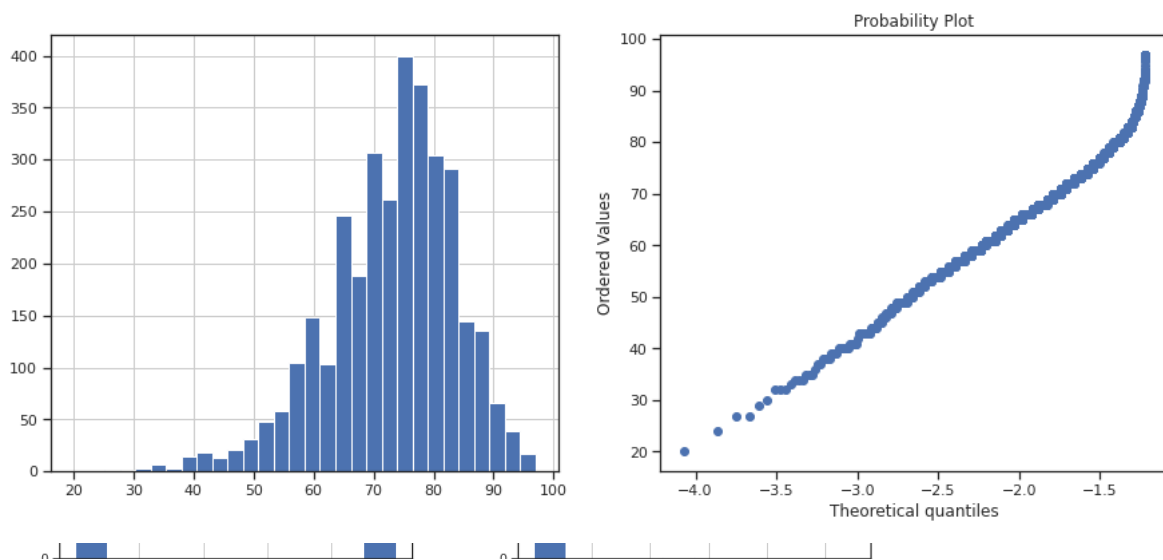
```
import scipy.stats as stats

def diagnostic_plots(df, variable):
    plt.figure(figsize=(15,6))
    # гистограмма
    plt.subplot(1, 2, 1)
    df[variable].hist(bins=30)
    ## Q-Q plot
    plt.subplot(1, 2, 2)
    stats.probplot(df[variable], dist="norm", plot=plt)
    plt.show()


data.hist(figsize=(20,20))
plt.show()
```





```
diagnostic_plots(data, 'Metacritic')
```





```
data['Metacritic_log'] = np.log(data['Metacritic'])
diagnostic_plots(data, 'Metacritic_log')
```





```
data['Metacritic_sqr'] = data['Metacritic']**(1/2)
diagnostic_plots(data, 'Metacritic_sqr')
```



```
data['Metacritic_exp1'] = data['Metacritic']**(1/1.5)
diagnostic_plots(data, 'Metacritic_exp1')
```



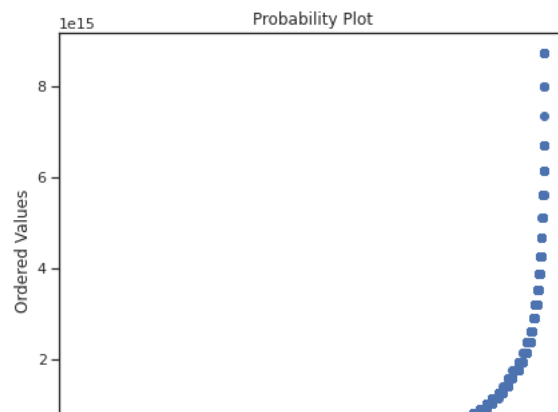

```
data['Metacritic_exp2'] = data['Metacritic']**(1.3)
diagnostic_plots(data, 'Metacritic_exp2')
```



Не очень хорошие результаты:

```
data['Metacritic'] = data['Metacritic'].astype('float')
data['Metacritic_yeojohnson'], param = stats.yeojohnson(data['Metacritic'])
print('Оптимальное значение  $\lambda$  = {}'.format(param))
diagnostic_plots(data, 'Metacritic_yeojohnson')
```

Оптимальное значение $\lambda = 8.472135811722177$



```
data['Metacritic_boxcox'], param = stats.boxcox(data['Metacritic'])
print('Оптимальное значение  $\lambda = \{ }\$ '.format(param))
diagnostic_plots(data, 'Metacritic_boxcox')
```

Оптимальное значение $\lambda = 8.472135811722177$

