Гаврилов Л.Я. ИУ5-23М

Вариант 4

Каждая задача предполагает использование набора данных.

Набор данных выбирается Вами произвольно с учетом следующих условий:

- Вы можете использовать один набор данных для решения всех задач, или решать каждую задачу на своем наборе данных.
- Набор данных должен отличаться от набора данных, который использовался в лекции для решения рассматриваемой задачи.
- Вы можете выбрать произвольный набор данных (например тот, который Вы использовали в лабораторных работах) или создать собственный набор данных (что актуально для некоторых задач, например, для задач удаления псевдоконстантных или повторяющихся признаков).
- Выбранный или созданный Вами набор данных должен удовлетворять условиям поставленной задачи. Например, если решается задача устранения пропусков, то набор данных должен содержать пропуски.

Номер задачи №1 - 4

Номер задачи №2 - 24

Задача №4.

Для набора данных проведите кодирование одного (произвольного) категориального признака с использованием метода "label encoding".

Задача №24.

Для набора данных для одного (произвольного) числового признака проведите обнаружение и удаление выбросов на основе 5% и 95% квантилей.

Дополнительные требования:

Для пары произвольных колонок данных построить график "Диаграмма рассеяния".

Загрузка и первичный анализ данных

```
import numpy as np
import pandas as pd
import seaborn as sns
```

```
data = pd.read_csv('bike-hour.csv', sep=",")
```

```
data.head(5)
```

	instant	dteday	season	mnth	hr	holiday	weekday	workingday	weathersit	temp
0	1	01-01-2011	1	1	0	0	6	0	1	0.24
1	2	01-01-2011	1	1	1	0	6	0	1	0.22
2	3	01-01-2011	1	1	2	0	6	0	1	0.22
3	4	01-01-2011	1	1	3	0	6	0	1	0.24
4	5	01-01-2011	1	1	4	0	6	0	1	0.24

Датасет

Информация об атрибутах:

- instant: индекс записи
- dteday: дата
- season: Сезон (1: зима, 2: весна, 3: лето, 4: осень)
- mnth: месяц (от 1 до 12)
- hour: час (от 0 до 23)
- holiday: выходной или нет
- weekday: день недели
- workingday: если день не является ни выходным, ни праздничным - 1, в противном случае - 0.

- weathersit:

  1: Ясно, Небольшая облачность, Небольшая облачность,

  2: Туман + Облачно, Туман + Разбитые облака, Туман + Несколько облаков, Туман

  3: слабый снег, легкий дождь + гроза + рассеянные облака, легкий дождь + рассеянные облака

  4: сильный дождь + ледяные поддоны + гроза + туман, снег + туман
- temp: нормализованная температура в градусах Цельсия
- atemp: нормализованная температура ощущения в градусах Цельсия
- hum: нормализованная влажность
- windspeed: нормализованная скорость ветра
- casul: количество случайных прохожих
- cnt: общее количество взятых напрокат велосипедов

```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 8645 entries, 0 to 8644
Data columns (total 15 columns):
 #   Column      Non-Null Count  Dtype  
---  ------      --------------  -----  
 0   instant     8645 non-null   int64  
 1   dteday      8645 non-null   object 
 2   season      8645 non-null   int64  
 3   mnth        8645 non-null   int64  
 4   hr          8645 non-null   int64  
 5   holiday     8645 non-null   int64  
 6   weekday     8645 non-null   int64  
 7   workingday  8645 non-null   int64  
 8   weathersit  8645 non-null   int64  
 9   temp        8645 non-null   float64
 10  atemp       8645 non-null   float64
 11  hum         8645 non-null   float64
 12  windspeed   8645 non-null   float64
 13  casual      8645 non-null   int64  
 14  cnt         8645 non-null   int64  
dtypes: float64(4), int64(10), object(1)
memory usage: 1013.2+ KB
```

```
data.describe()
```

	instant	season	mnth	hr	holiday	weekday	w
count	8645.000000	8645.000000	8645.000000	8645.000000	8645.000000	8645.000000	86
mean	4323.000000	2.513592	6.573973	11.573626	0.027646	3.012724	
std	2495.740872	1.105477	3.428147	6.907822	0.163966	2.006370	
min	1.000000	1.000000	1.000000	0.000000	0.000000	0.000000	
25%	2162.000000	2.000000	4.000000	6.000000	0.000000	1.000000	
50%	4323.000000	3.000000	7.000000	12.000000	0.000000	3.000000	

Задача №4.

Для набора данных проведите кодирование одного (произвольного) категориального признака с использованием метода "label encoding".

```
total_count = data.shape[0]
print('Всего строк: {}'.format(total_count))
```

```
Всего строк: 8645
```

```
# Выберем категориальные колонки с пропущенными значениями
# Цикл по колонкам датасета
cat_cols = []
for col in data.columns:
    # Количество пустых значений
    temp_null_count = data[data[col].isnull()].shape[0]
    dt = str(data[col].dtype)
    if temp_null_count>=0 and (dt=='object'):
        cat_cols.append(col)
        temp_perc = round((temp_null_count / total_count) * 100.0, 2)
        print('Колонка {}. Тип данных {}. Количество пустых значений {}, {}%.'.format(col,
```

```
Колонка dteday. Тип данных object. Количество пустых значений 0, 0.0%.
```

```
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
```

```
cat_enc = pd.DataFrame({'c1':data['dteday']})
cat_enc
```

	c1
0	01-01-2011
1	01-01-2011
2	01-01-2011
3	01-01-2011
4	01-01-2011
...	...
8640	31-12-2011

```
le = LabelEncoder()
cat_enc_le = le.fit_transform(cat_enc['c1'])
```

```
cat_enc['c1'].unique()
```

```
array(['01-01-2011', '02-01-2011', '03-01-2011', '04-01-2011',
       '05-01-2011', '06-01-2011', '07-01-2011', '08-01-2011',
       '09-01-2011', '10-01-2011', '11-01-2011', '12-01-2011',
       '13-01-2011', '14-01-2011', '15-01-2011', '16-01-2011',
       '17-01-2011', '18-01-2011', '19-01-2011', '20-01-2011',
       '21-01-2011', '22-01-2011', '23-01-2011', '24-01-2011',
       '25-01-2011', '26-01-2011', '27-01-2011', '28-01-2011',
       '29-01-2011', '30-01-2011', '31-01-2011', '01-02-2011',
       '02-02-2011', '03-02-2011', '04-02-2011', '05-02-2011',
       '06-02-2011', '07-02-2011', '08-02-2011', '09-02-2011',
       '10-02-2011', '11-02-2011', '12-02-2011', '13-02-2011',
       '14-02-2011', '15-02-2011', '16-02-2011', '17-02-2011',
       '18-02-2011', '19-02-2011', '20-02-2011', '21-02-2011',
       '22-02-2011', '23-02-2011', '24-02-2011', '25-02-2011',
       '26-02-2011', '27-02-2011', '28-02-2011', '01-03-2011',
       '02-03-2011', '03-03-2011', '04-03-2011', '05-03-2011',
       '06-03-2011', '07-03-2011', '08-03-2011', '09-03-2011',
       '10-03-2011', '11-03-2011', '12-03-2011', '13-03-2011',
       '14-03-2011', '15-03-2011', '16-03-2011', '17-03-2011',
       '18-03-2011', '19-03-2011', '20-03-2011', '21-03-2011',
       '22-03-2011', '23-03-2011', '24-03-2011', '25-03-2011',
       '26-03-2011', '27-03-2011', '28-03-2011', '29-03-2011',
       '30-03-2011', '31-03-2011', '01-04-2011', '02-04-2011',
       '03-04-2011', '04-04-2011', '05-04-2011', '06-04-2011',
       '07-04-2011', '08-04-2011', '09-04-2011', '10-04-2011',
       '11-04-2011', '12-04-2011', '13-04-2011', '14-04-2011',
       '15-04-2011', '16-04-2011', '17-04-2011', '18-04-2011',
       '19-04-2011', '20-04-2011', '21-04-2011', '22-04-2011',
       '23-04-2011', '24-04-2011', '25-04-2011', '26-04-2011',
       '27-04-2011', '28-04-2011', '29-04-2011', '30-04-2011',
       '01-05-2011', '02-05-2011', '03-05-2011', '04-05-2011',
       '05-05-2011', '06-05-2011', '07-05-2011', '08-05-2011',
       '09-05-2011', '10-05-2011', '11-05-2011', '12-05-2011',
       '13-05-2011', '14-05-2011', '15-05-2011', '16-05-2011',
       '17-05-2011', '18-05-2011', '19-05-2011', '20-05-2011',
       '21-05-2011', '22-05-2011', '23-05-2011', '24-05-2011',
       '25-05-2011', '26-05-2011', '27-05-2011', '28-05-2011',
       '29-05-2011', '30-05-2011', '31-05-2011', '01-06-2011',
```

```
'02-06-2011', '03-06-2011', '04-06-2011', '05-06-2011',
'06-06-2011', '07-06-2011', '08-06-2011', '09-06-2011',
'10-06-2011', '11-06-2011', '12-06-2011', '13-06-2011',
'14-06-2011', '15-06-2011', '16-06-2011', '17-06-2011',
'18-06-2011', '19-06-2011', '20-06-2011', '21-06-2011',
'22-06-2011', '23-06-2011', '24-06-2011', '25-06-2011',
'26-06-2011', '27-06-2011', '28-06-2011', '29-06-2011',
'30-06-2011', '01-07-2011', '02-07-2011', '03-07-2011',
'04-07-2011', '05-07-2011', '06-07-2011', '07-07-2011',
'08-07-2011', '09-07-2011', '10-07-2011', '11-07-2011',
'12-07-2011', '13-07-2011', '14-07-2011', '15-07-2011',
'16-07-2011', '17-07-2011', '18-07-2011', '19-07-2011',
'20-07-2011', '21-07-2011', '22-07-2011', '23-07-2011',
'24-07-2011', '25-07-2011', '26-07-2011', '27-07-2011',
'28-07-2011', '29-07-2011', '30-07-2011', '31-07-2011',
'01-08-2011', '02-08-2011', '03-08-2011', '04-08-2011',
'05-08-2011', '06-08-2011', '07-08-2011', '08-08-2011',
'09-08-2011', '10-08-2011', '11-08-2011', '12-08-2011',
'13-08-2011', '14-08-2011', '15-08-2011', '16-08-2011',
```

```
np.unique(cat_enc_le)
```

```
array([  0,   1,   2,   3,   4,   5,   6,   7,   8,   9,  10,  11,  12,
        13,  14,  15,  16,  17,  18,  19,  20,  21,  22,  23,  24,  25,
        26,  27,  28,  29,  30,  31,  32,  33,  34,  35,  36,  37,  38,
        39,  40,  41,  42,  43,  44,  45,  46,  47,  48,  49,  50,  51,
        52,  53,  54,  55,  56,  57,  58,  59,  60,  61,  62,  63,  64,
        65,  66,  67,  68,  69,  70,  71,  72,  73,  74,  75,  76,  77,
        78,  79,  80,  81,  82,  83,  84,  85,  86,  87,  88,  89,  90,
        91,  92,  93,  94,  95,  96,  97,  98,  99, 100, 101, 102, 103,
       104, 105, 106, 107, 108, 109, 110, 111, 112, 113, 114, 115, 116,
       117, 118, 119, 120, 121, 122, 123, 124, 125, 126, 127, 128, 129,
       130, 131, 132, 133, 134, 135, 136, 137, 138, 139, 140, 141, 142,
       143, 144, 145, 146, 147, 148, 149, 150, 151, 152, 153, 154, 155,
       156, 157, 158, 159, 160, 161, 162, 163, 164, 165, 166, 167, 168,
       169, 170, 171, 172, 173, 174, 175, 176, 177, 178, 179, 180, 181,
       182, 183, 184, 185, 186, 187, 188, 189, 190, 191, 192, 193, 194,
       195, 196, 197, 198, 199, 200, 201, 202, 203, 204, 205, 206, 207,
       208, 209, 210, 211, 212, 213, 214, 215, 216, 217, 218, 219, 220,
       221, 222, 223, 224, 225, 226, 227, 228, 229, 230, 231, 232, 233,
       234, 235, 236, 237, 238, 239, 240, 241, 242, 243, 244, 245, 246,
       247, 248, 249, 250, 251, 252, 253, 254, 255, 256, 257, 258, 259,
       260, 261, 262, 263, 264, 265, 266, 267, 268, 269, 270, 271, 272,
       273, 274, 275, 276, 277, 278, 279, 280, 281, 282, 283, 284, 285,
       286, 287, 288, 289, 290, 291, 292, 293, 294, 295, 296, 297, 298,
       299, 300, 301, 302, 303, 304, 305, 306, 307, 308, 309, 310, 311,
       312, 313, 314, 315, 316, 317, 318, 319, 320, 321, 322, 323, 324,
       325, 326, 327, 328, 329, 330, 331, 332, 333, 334, 335, 336, 337,
       338, 339, 340, 341, 342, 343, 344, 345, 346, 347, 348, 349, 350,
       351, 352, 353, 354, 355, 356, 357, 358, 359, 360, 361, 362, 363,
       364])
```

Таким образом, наблюдаем, что датасет содержит данные 365 дней в 2011 году, каждое значение из которых было преобразовано из категориального признака в числовой с помощью label encoding.

Задача №24.

Для набора данных для одного (произвольного) числового признака проведите обнаружение и удаление выбросов на основе 5% и 95% квантилей.

```
data = pd.read_csv('games.csv', sep=",")
```

```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 30250 entries, 0 to 30249
Data columns (total 27 columns):
 #   Column            Non-Null Count  Dtype  
---  ------            --------------  -----  
 0   Unnamed: 0        30250 non-null  int64  
 1   id                30250 non-null  int64  
 2   Name              30156 non-null  object 
 3   RawgID            30156 non-null  float64
 4   SteamURL          30195 non-null  object 
 5   Metacritic        3356 non-null   float64
 6   Genres            27282 non-null  object 
 7   Indie             30045 non-null  float64
 8   Presence          30156 non-null  float64
 9   Platform          30123 non-null  object 
 10  Graphics          25930 non-null  object 
 11  Storage           27491 non-null  object 
 12  Memory            28316 non-null  object 
 13  RatingsBreakdown  15044 non-null  object 
 14  ReleaseDate       27024 non-null  object 
 15  Soundtrack        30045 non-null  float64
 16  Franchise         5087 non-null   object 
 17  OriginalCost      29504 non-null  object 
 18  DiscountedCost    727 non-null    object 
 19  Players           12334 non-null  object 
 20  Controller        29976 non-null  float64
 21  Languages         30027 non-null  object 
 22  ESRB              4747 non-null   object 
 23  Achievements      30156 non-null  float64
 24  Publisher         0 non-null      float64
 25  Description       30031 non-null  object 
 26  Tags              30045 non-null  object 
dtypes: float64(8), int64(2), object(17)
memory usage: 6.2+ MB
```

```
data = data.drop('Publisher', 1)
data = data.drop('Unnamed: 0', 1)
data = data.dropna(axis=0, subset=['Name', 'SteamURL'])
data.shape
```

```
<ipython-input-87-aefd0e2a8e93>:1: FutureWarning: In a future version of pandas all
  data = data.drop('Publisher', 1)
<ipython-input-87-aefd0e2a8e93>:2: FutureWarning: In a future version of pandas all
```

```
  data = data.drop('Unnamed: 0', 1)
(30101, 25)
```

```
hcols_with_na = [c for c in data.columns if data[c].isnull().sum() > 0]
# Количество пропусков
[(c, data[c].isnull().sum()) for c in hcols_with_na]
```

```
[('Metacritic', 26746),
 ('Genres', 2907),
 ('Indie', 176),
 ('Platform', 33),
 ('Graphics', 4250),
 ('Storage', 2697),
 ('Memory', 1872),
 ('RatingsBreakdown', 15112),
 ('ReleaseDate', 3132),
 ('Soundtrack', 176),
 ('Franchise', 25024),
 ('OriginalCost', 688),
 ('DiscountedCost', 29374),
 ('Players', 17813),
 ('Controller', 219),
 ('Languages', 168),
 ('ESRB', 25355),
 ('Description', 125),
 ('Tags', 176)]
```

```
import matplotlib.pyplot as plt
import scipy.stats as stats


# Тип вычисления верхней и нижней границы выбросов
from enum import Enum
class OutlierBoundaryType(Enum):
    QUANTILE = 1


# Функция вычисления верхней и нижней границы выбросов
def get_outlier_boundaries(df, col, outlier_boundary_type: OutlierBoundaryType):
    if outlier_boundary_type == OutlierBoundaryType.QUANTILE:
        lower_boundary = df[col].quantile(0.05)
        upper_boundary = df[col].quantile(0.95)

    return lower_boundary, upper_boundary


def diagnostic_plots(df, variable, title):
    fig, ax = plt.subplots(figsize=(10,7))
    # гистограмма
    plt.subplot(2, 2, 1)
    df[variable].hist(bins=30)
    ## Q-Q plot
    plt.subplot(2, 2, 2)
    stats.probplot(df[variable], dist="norm", plot=plt)
    # ящик с усами
```

```
    plt.subplot(2, 2, 3)
    sns.violinplot(x=df[variable])
    # ящик с усами
    plt.subplot(2, 2, 4)
    sns.boxplot(x=df[variable])
    fig.suptitle(title)
    plt.show()


x_col_list = ['Metacritic']


diagnostic_plots(data, 'Metacritic', 'Metacritic - original')
```

```
    <ipython-input-92-1fe78d5d2ee2>:4: MatplotlibDeprecationWarning: Auto-removal of ove
      plt.subplot(2, 2, 1)
```

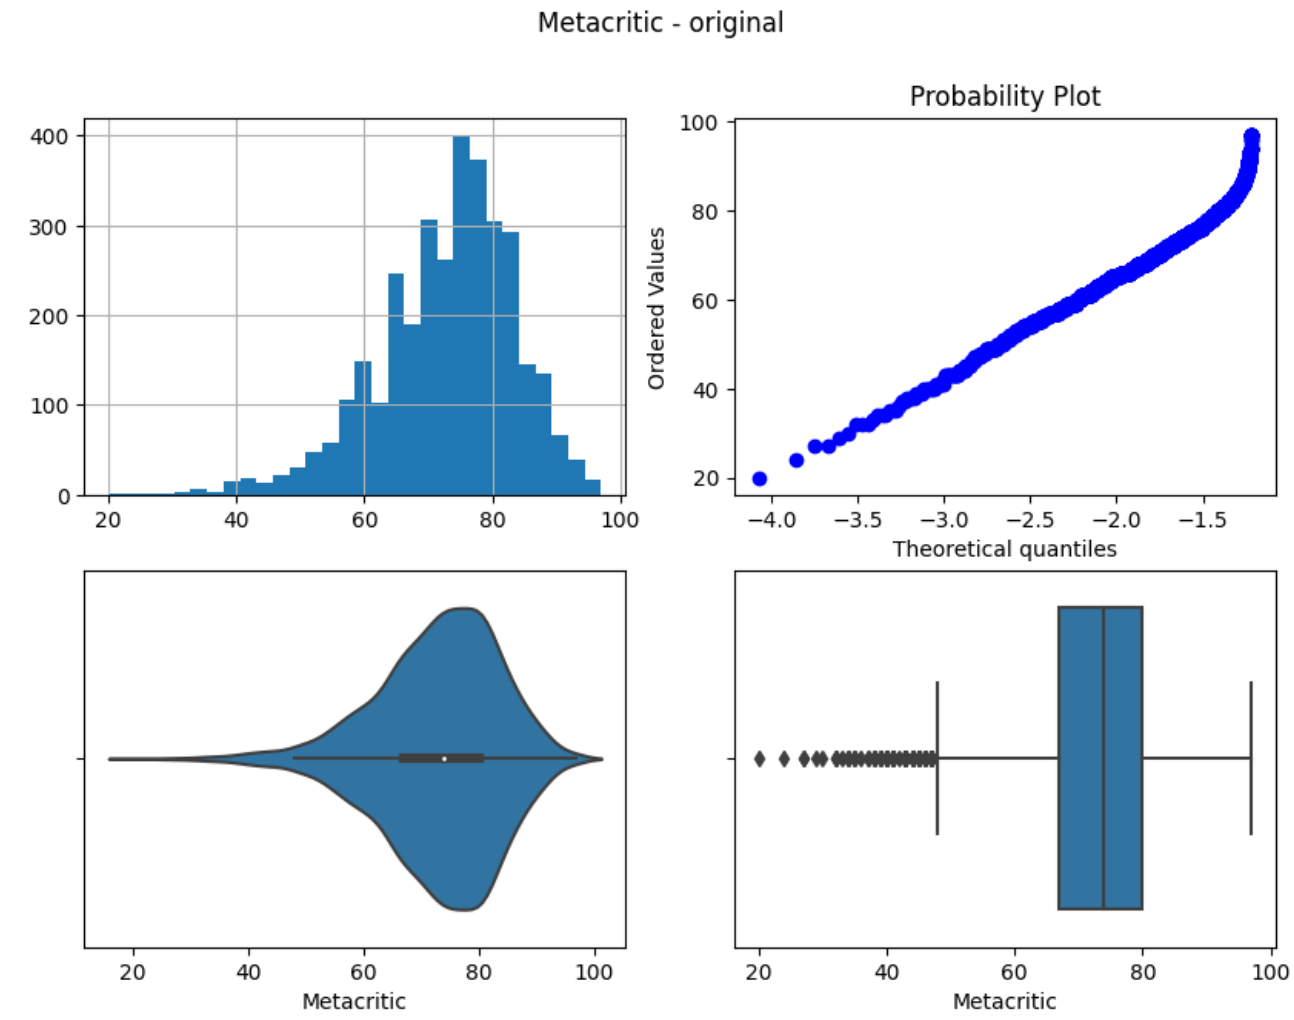

```
    for col in x_col_list:
        for obt in OutlierBoundaryType:
            # Вычисление верхней и нижней границы
            lower_boundary, upper_boundary = get_outlier_boundaries(data, col, obt)
            # Флаги для удаления выбросов
            outliers_temp = np.where(data[col] > upper_boundary, True,
                                     np.where(data[col] < lower_boundary, True, False))
            # Удаление данных на основе флага
            data_trimmed = data.loc[~(outliers_temp), ]
            title = 'Поле-{}, метод-{}, строк-{}'.format(col, obt, data_trimmed.shape[0])
            diagnostic_plots(data_trimmed, col, title)
```

```
<ipython-input-92-1fe78d5d2ee2>:4: MatplotlibDeprecationWarning: Auto-removal of ove
  plt.subplot(2, 2, 1)
```

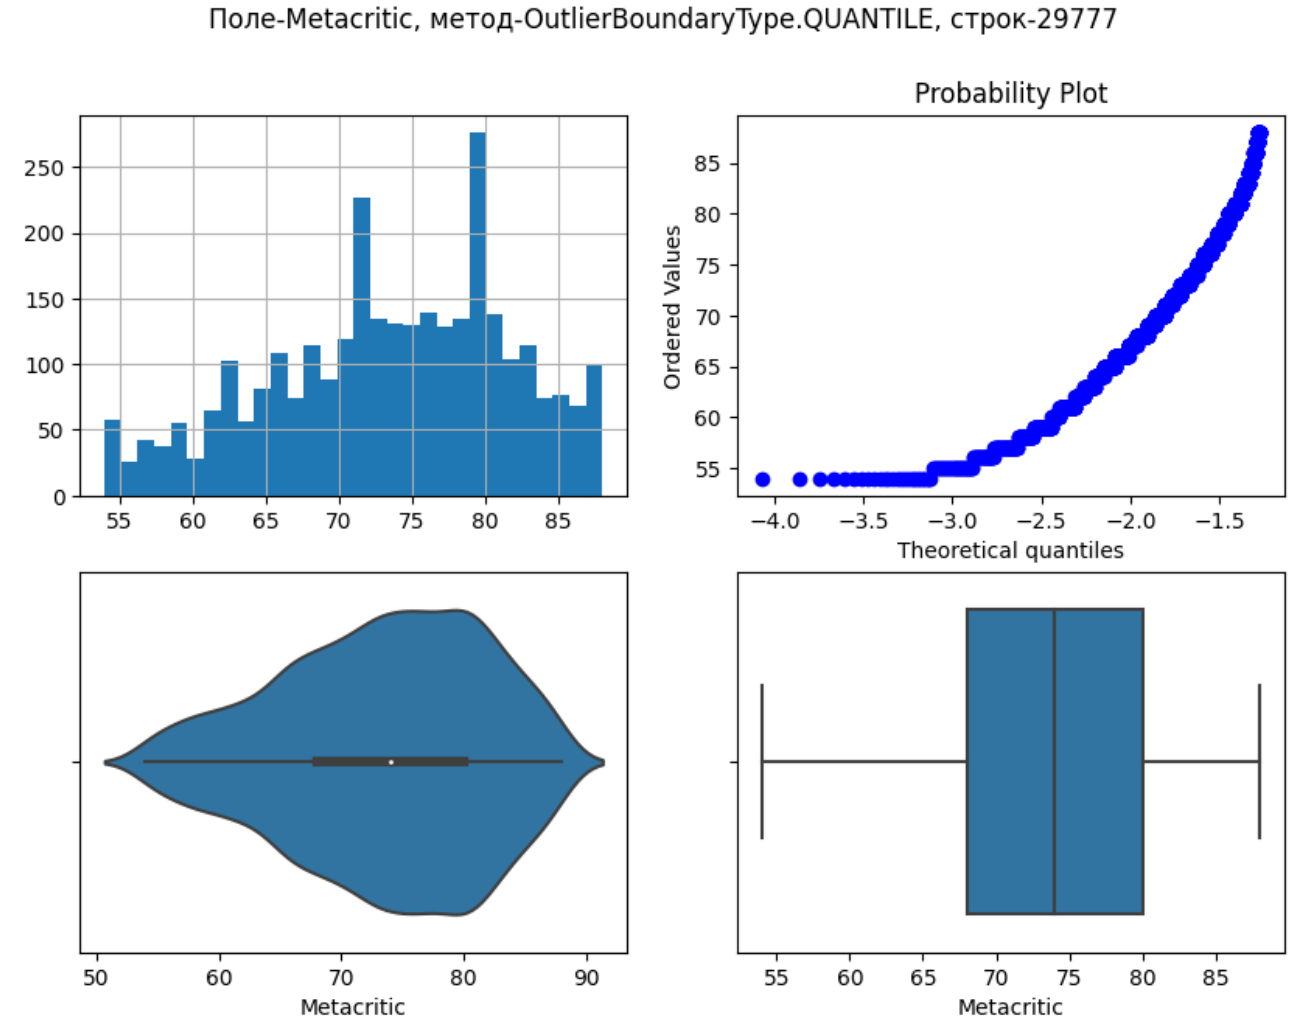

Дополнительное задание

Для пары произвольных колонок данных построить график "Диаграмма рассеяния".

Построим диаграмму рассеяния, демонстрирующую зависимость температуры от месяца года

```
data = pd.read_csv('bike-hour.csv', sep=",")
```

```
data.plot(x='mnth', y='temp', kind='scatter',  figsize=(25, 15)) ;
plt.title(f'Распределение температуры по месяцам', fontsize=15);
plt.ylim(0,1);
plt.ylabel('Нормированная температура');
plt.xlabel('Месяцы');
plt.grid(True);
```

```
/usr/local/lib/python3.9/dist-packages/pandas/plotting/_matplotlib/core.py:1114: Use
  scatter = ax.scatter(
```